



山东大学
SHANDONG UNIVERSITY

毕业论文(设计)

论文(设计)题目: 基于 GAN 的无线信道建模技术研究

Research on Wireless Channel Modeling Technology Based
on GAN

姓 名_____王浩岩_____

学 号_____202000120142_____

学 院_____信息科学与工程学院_____

专 业_____通信工程_____

年 级_____2020 级_____

指导教师_____孙健_____

2024 年 5 月 28 日

摘要

近年来，深度学习技术以其惊人的速度迭代创新，逐渐渗透至各个学科领域，特别是在通信工程领域，深度神经网络被越来越多地视为应对传统挑战和优化解决方案的重要手段。随着无线通信系统朝着多输入多输出（MIMO）技术的深化发展，信道建模所面临的复杂性和不确定性呈现出指数级增长，获取足够数量且质量优良的无线信道数据也因其高昂的成本成为了制约研究进展的关键瓶颈。

本文应用生成对抗网络（Generative Adversarial Networks, GANs）框架革新无线通信中的信道建模过程。精心设计了一种基于条件生成对抗网络（Conditional GANs, CGANs）的方法，利用其强大的非线性表达能力和内在的竞争学习机制，力求精确捕捉和再现 MIMO 信道的复杂特性。然而，标准 GAN 在训练过程中常常面临稳定性欠佳的问题，比如梯度消失或梯度爆炸现象可能导致生成器无法产出多样且逼真的信道样本。为此，在原 CGAN 架构基础上引入了更为稳定且理论上有保证收敛性的 Wasserstein GAN（WGAN）方案，不仅改善了训练过程的稳定性，还显著提升了生成样本的质量和多样性。

实证研究阶段，在 DeepMIMO 仿真平台搭建的典型城市十字路口场景下，应用 WGAN-based 信道建模方法生成了信道的路径参数，并将路径参数映射为频域信道矩阵，在此场景中模拟一个运动目标，计算随时间变化的功率时延谱 PDP，通过对生成的虚拟信道数据与仿真信道数据的 PDP 进行对比分析，验证了所生成信道与仿真信道间在统计特性上的一致性，确保了生成数据的可靠性和有效性。这项工作是对大规模高质量无线信道数据的模拟生成的尝试，有效缓解了现实条件下数据采集难、成本高的问题。

关键词：无线信道建模；GAN；CGAN；神经网络；深度学习

ABSTRACT

In recent years, deep learning technology has iteratively innovated at an astonishing speed and gradually penetrated into various disciplines, especially in the field of communication engineering. Deep neural networks are increasingly seen as an important means to address traditional challenges and optimize solutions. With the deepening development of wireless communication systems towards multi input multi output (MIMO) technology, the complexity and uncertainty faced by channel modeling have shown exponential growth. Obtaining sufficient and high-quality wireless channel data has also become a key bottleneck restricting research progress due to its high cost.

This thesis applies the Generative Adversarial Networks (GANs) framework to revolutionize the channel modeling process in wireless communication. A method based on Conditional GANs (CGANs) has been carefully designed, utilizing its powerful non-linear expression ability and inherent competitive learning mechanism to accurately capture and reproduce the complex characteristics of MIMO channels. However, standard GANs often face issues of poor stability during the training process, such as vanishing or exploding gradients, which may prevent the generator from producing diverse and realistic channel samples. To this end, a more stable and theoretically guaranteed convergence Wasserstein GAN (WGAN) scheme was introduced on the basis of the original CGAN architecture, which not only improved the stability of the training process, but also significantly improved the quality and diversity of generated samples.

In the empirical research stage, in a typical urban intersection scenario built on the DeepMIMO simulation platform, the WGAN based channel modeling method was applied to generate the path parameters of the channel, and the path parameters were mapped to a frequency domain channel matrix. In this scenario, a moving target was simulated, and the time-varying power delay spectrum PDP was calculated. By comparing and analyzing the PDP of the generated virtual channel data and the simulated channel data, the statistical consistency between the generated channel and the simulated channel was verified, ensuring the reliability and effectiveness of the

generated data. This work is an attempt to simulate the generation of large-scale high-quality wireless channel data, effectively alleviating the difficulties and high costs of data collection under realistic conditions.

Key Words: Wireless channel modeling, GAN, CGAN, Neural Network, Deep Learning

目 录

| | |
|---------------------------------|----|
| 第 1 章 引言 | 1 |
| 1.1 研究背景及意义 | 1 |
| 1.2 国内外研究现状 | 1 |
| 1.2.1 GAN 及其衍生模型研究现状 | 1 |
| 1.2.2 GAN 在信道建模领域应用现状 | 3 |
| 1.3 深度学习技术在通信领域的应用 | 4 |
| 1.4 论文主要工作及结构安排 | 5 |
| 第 2 章 相关神经网络基本原理 | 6 |
| 2.1 ChannelGAN 中的 WGAN-GP | 6 |
| 2.2 改进的 WGAN-GP | 7 |
| 2.2.1 WGAN-GP 基本框架 | 7 |
| 2.2.2 WGAN-GP 改进算法 | 8 |
| 2.3 CGAN | 9 |
| 2.3.1 CGAN 基本框架 | 9 |
| 2.3.2 CGAN 网络结构 | 9 |
| 2.4 ACGAN | 10 |
| 2.4.1 ACGAN 基本框架 | 10 |
| 2.4.2 ACGAN 网络结构 | 11 |
| 2.5 提出的信道生成网络结构 | 12 |
| 2.6 本章小结 | 13 |
| 第 3 章 基于 CGAN 的信道数据生成 | 14 |
| 3.1 设计背景 | 14 |
| 3.2 信道模型 | 14 |
| 3.3 数据集建立 | 15 |
| 3.4 网络训练 | 17 |
| 3.5 信道生成仿真结果 | 20 |
| 3.5.1 信道数据生成 | 20 |
| 3.5.2 真假信道功率时延谱对比 | 21 |
| 3.6 本章小结 | 23 |
| 第 4 章 总结与展望 | 24 |
| 参考文献 | 25 |
| 致 谢 | 27 |

第1章 引言

1.1 研究背景及意义

信道建模是无线通信系统设计和性能评估的基础。然而，考虑到无线环境日益复杂、频段扩展以及大规模多输入多输出（MIMO）系统的引入，当前的信道建模方案难以有效地提取复杂的无线特征^[1]。寻找能够解决这些问题的信道建模方案已成为无线通信研究的一个重要课题。

近年来，基于深度学习（DL）的无线通信被认为是6G的潜在技术^[2]。在通信系统中实现深度学习，除了建立准确可靠的信道模型之外，为了支持神经网络（NN）的训练，还需要大量高质量的无线信道数据集^[3]。与之对应的问题是，收集足够多无线信道数据的成本较高，耗时较长，这促使人们寻找更加高效低成本信道数据生成解决方案。

对于加性高斯白噪声（AWGN）和多路径单输入单输出（SISO）信道，当前已经由较为完善的GAN建模方法，在此基础上，还需要进一步考虑部分关键因素。例如，在现实中大量获取真实信道数据有较大难度，此外，仅对AWGN和SISO信道建模仍不能满足无线信道研究的需要，应考虑更为复杂的信道场景。

在本文中，提出了一种基于GAN的信道建模和生成方法。具体来说，是将带标签的真实信道数据集输入条件生成对抗网络（CGAN或ACGAN），结合改进的WGAN-GP的神经网络结构与训练算法，搭建模型并进行训练，实现不同类别信道数据的生成。本文实现了指定用户位置坐标的信道路径参数生成，并根据基于几何的随机信道模型GBSM将路径参数映射为频域信道矩阵。

1.2 国内外研究现状

1.2.1 GAN 及其衍生模型研究现状

生成对抗网络（Generator Advertise Networks, GAN）的概念由Goodfellow于2014年提出，该网络包含一个生成器和一个判别器模型，二者的目标分别是将目标函数最大化和最小化，在对抗训练的过程中，生成器要尽可能提高自身的生成能力，提高生成样本的真实性。判别器要在不知道输入数据是否是真实数据还是生成器生成的数据的情况下判断数据的真假。二者在对抗中提升自身的能力。

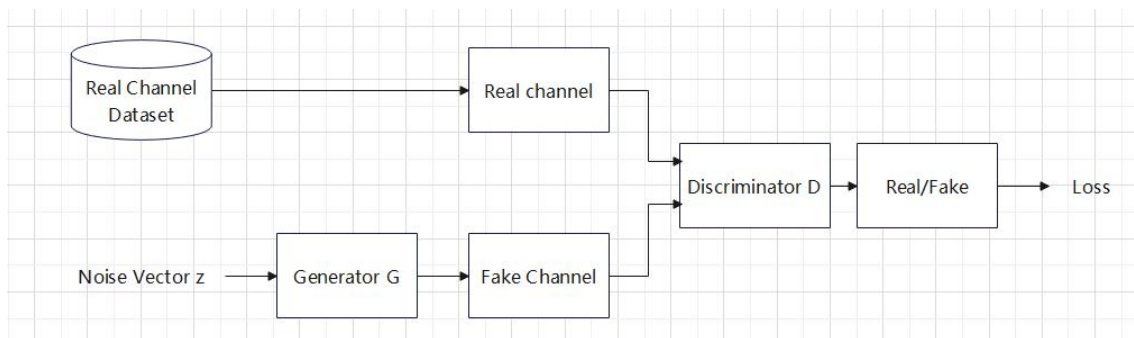


图 1 GAN 基本框架

简单的 GAN 网络经过迭代训练后,生成效果不够理想^[4]。为了改善这一问题,在 GAN 提出的同年,Mirza 通过在 GAN 中引入条件信息,将网络的输入由单纯的随机噪声改造为噪声与条件组合后共同输入隐藏层,形成了条件生成对抗网络(Conditional Generator Advertise Networks, CGAN)^[5]。条件信息通常是代表类别的标签,使生成器具有定向生成的能力,更好地模拟真实样本。

2015 年, Denton 等人根据卷积神经网络参数共享和局部连接的特点, 提出了一种能够生成高质量自然图像样本的生成参数模型, 该模型结合了深度卷积神经网络与 GAN, 进一步提高了 GAN 生成能力。实验过程中生成的 CIFAR10 样本在大约 40% 的时间内都被判别器判断为真实图像, 而从常规 GAN 模型中提取的样本仅有 10% 判断为真实图像^[6]。

对于 GAN 存在的训练不稳定、生成样本单一问题, Arjovsky 经过研究, 在 GAN 网络中引入 Wasserstein 距离, 提出了 WGAN(Wasserstein Generative Advertise Networks, WGAN) 模型, 使用 Wasserstein 距离计算生成样本和真实样本之间的距离^[7]。Wasserstein 距离较为平滑, 能够显著提高网络训练的稳定性。WGAN 的缺点是需要使惩罚函数满足 Lipschitz 约束, 以实现权重剪枝 (Weight Clipping), 在超出约束范围的情况下进行权重剪枝, 会引发梯度消失和梯度爆炸等问题, 因此要求约束必须在合理的范围内实现。同年, Gulrajani 提出了一种代替权重剪枝的方法, 能够针对损失函数的输入引入梯度惩罚, 解决梯度消失和梯度爆炸问题, 称为 WGAN-GP (Wasserstein Generative Advertise Networks-Gradient Penalty, WGAN-GP) ^[8]。

传统的 GAN 在生成图像时往往面临着模式坍塌的问题，即生成的图像缺乏多样性，无法覆盖所有可能的输出。为了解决这个问题，ACGAN（Conditional Generative Adversarial Networks）被提出。使用标签的数据集应用于生成对抗

网络增强现有生成模型的两种优化思路为 CGAN 和 SGAN：CGAN 使通过向数据加入区分类别的标签来增强原始 GAN，生成器和判别器的输入均在 GAN 的基础上拼接标签向量，为数据生成指定了方向；SGAN 的结构来利用辅助标签信息（少量标签），利用判别器或者分类器的末端重建标签信息。ACGAN 则是结合了以上两种思路对 GAN 进行了优化^[9]。

1.2.2 GAN 在信道建模领域应用现状

近年来，深度学习在无线通信领域发展迅速，包括信道建模。到目前为止，基于生成对抗网络的信道建模已经引起了广泛的关注。

2019 年，Y. Yang 等人提出了一种 GAN 框架，以解决无需复杂理论分析或数据处理的自主无线信道建模问题，引入了基于 GAN 的信道建模方法，对加性白高斯噪声（AWGN）信道进行了建模^[10]。并对比了传统信道建模框架与 GAN 建模框架的性能和有效性，完成了基于 GAN 信道建模的先驱工作。

同年，Seyedsalehi 将 StarGAN 用于根据所需的用户速度更改生成的信道图像，提出了基于 GAN 对多路径单输入单输出（SISO）^[11]信道建模的方法，

2022 年，Divpreet Singh 提出，基于 GAN 的信道模型可用于现有信道模型无法准确捕获传播场景的频率选择性时变场景以及通过现有信道模型捕获的场景，应用卷积 GAN 对时变和频率选择信道进行了建模^[12]。

同年，Han Xiao 在 AWGN 和 SISO 信道建模的基础上，进一步研究一个更复杂、更实际的场景，提出了利用 WGAN-GP 来捕获 MIMO 信道的空间相关性，并学习信道状态信息（Channel State Information, CSI）的分布，即 ChannelGAN，实现了 CDL 信道模型的建模，并进行交叉验证，评估了基于 DL 的信道状态信息（CSI）反馈的有效性和可用性。且该方案可以自然地扩展到更复杂的信道条件。

同年，Sundeep Rangan 等人提出了变分自编码器（VAE），用于根据发射天线 Tx 和接收天线 Rx 之间的距离生成空对地（A2G）信道的信道参数，该自动编码器生成所有传播路径的路径损耗、延迟以及到达和离开角度^[13]。实现了面向毫米波无人机通信的生成神经网络信道建模。但是，不同 Tx 和 Rx 位置但距离相同生成的信道参数相同，这与实际信道不一致。

2024 年，Yue Tian 等人考虑到无人机通信的三维散射空间和高动态特性，提出了一种基于条件生成对抗网络（CGAN）的 A2G 通信场景信道建模方法^[14]，所提出的基于 CGN 的方法可以从同一场景下采样位置的有限测量或模拟信道数据中生

成无人机和地面站（GS）任意位置的信道参数。此外，根据获得的信道参数可以得到信道脉冲响应（CIR），并利用所提出的基于 CGAN 的方法捕获 A2G 通信场景的信道特性。

1.3 深度学习技术在通信领域的应用

深度学习正逐渐在各个领域成为热点技术，在多个领域的成功案例让人们开始重视深度学习方法在通信系统中的作用。

2016 年，O’ Shea 初步探讨了深度学习在端到端通信系统中的应用，并提出一种利用信道自动编码器中的人工损伤层优化重建损失的物理层编码^[15]，引入了几个新的正则化层来模拟常见的无线信道损伤，解决了学习高效且自适应的物理层编码的问题，并通过实验证明这种结构在对通信系统的学习中更加高效。

2018 年，Timothy 等人提出使用 GAN 网络学习任意通信信道的函数近似^[16]。通过联合学习信道函数近似和编码器/解码器方案，该系统可以在未知特征的物理信道上完成学习，并且实现了能够支持编码器和解码器网络的函数近似。

2020 年，吴楠等人提出了一种能够实现编码、解码、调制、解调等工作的基于 CNN 的自编码器通信系统^[17]，实验结果表明，在不同码速和块长度的通信系统中，基于卷积神经网络的系统性能与过去设计的最佳方案详尽，且体现出了较强的泛用能力，能够适用于多种类型的信道，均可完成训练目标

同年，Song Guo 等人提出了一种更高效的方案，适用于基于深度学习的 5G 场景。同时介绍了几种重要的基于深度学习的通信方法的关键思想^[18]。特别研究了 NOMA 通信、大规模 MIMO 和毫米波（mmWave）的新型通信框架，并展示了其优越的性能。

2021 年，Han Xiao 等人给出了全信道状态信息（F-CSI）反馈问题框架及其对应的信道数据集；然后，阐述了基于深度学习的 F-CSI 反馈增强方案，包括信道数据分析预处理、神经网络设计和量化增强。列出了基于 AI 的无线通信系统设计的一些挑战和潜在的研究领域^[19]。

对深度学习技术在无线通信领域应用的研究仍处在发展阶段，无线通信环境日益复杂，适用于不同信道模型的网络设计方法和训练方法也不同。网络结构和训练方法仍需要不断优化，以适应无线通信对信道模型准确性和可靠性的不断提高。

1.4 论文主要工作及结构安排

本文的主要进行的研究工作如下：

（1）阐述 GAN 及其部分衍生模型的基本原理，研究 WGAN-GP、CGAN、ACGAN 模型基本原理与框架，明确各个模型应用于数据生成的优缺点，构建大致的网络模型，为后续信道数据生成工作奠定理论基础。

（2）明确设计背景，确定要研究的信道模型，通过 DeepMIMO 平台生成信道数据集，设置数据集相关参数，完成两种信道形式数据集的分割和数据预处理。为模型构建，信道数据生成做准备。

（3）设计神经网络模型，根据两种数据集的特征分别构建对应的 ACGAN 网络模型，并根据改进的 WGAN-GP 计算带梯度惩罚的损失函数，确定训练方法，将训练集信道数据集输入构建好的模型进行训练，完成生成器和判别器的更新，保存更新完成后的生成器与判别器模型。

（4）利用测试数据集输入训练完成的模型，实现指定用户位置的信道数据的生成，评估信道数据仿真结果，对比生成的信道矩阵与测试集中的信道矩阵，验证生成的信道数据的有效性和可靠性。

本文共设置四章，各章节结构安排如下：

第一章 引言。本章概述了基于 GAN 的无线信道建模技术的研究目的与研究意义，同时介绍了国内外相关研究的发展现状以及深度学习技术在通信领域的应用。

第二章 相关神经网络基本原理。本章研究了 GAN 及其部分衍生模型的基本原理，对每一种模型给出了大致的网络结构。

第三章 基于 GAN 的信道数据生成。本章针对两种不同的无线信道形式，提出了基于 CGAN 和 ACGAN 的建模方法，完成了数据集获取、网络模型构建、确定训练算法、训练网络、数据生成、真假信道对比、数据有效性评估一系列工作。

第四章。总结与展望，本章简单总结了本文的全部研究工作，阐述了 GAN 模型在信道建模方面存在的优势与不足，并结合当前研究现状对 GAN 技术在通信领域的发展前景进行了展望。

第2章 相关神经网络基本原理

2.1 ChannelGAN中的WGAN-GP

ChannelGAN 是 GAN 的一种变体,更具体地说,ChannelGAN 中的发生器和鉴别器是由具有卷积层叠加的上下采样块组成的组合。总体而言,ChannelGAN 生成的假数据与真实通道数据具有一致的归一化能力^[20]。

原始的 GAN 存在的问题是,判别器参数越接近最优,生成器梯度消失越严重,会导致训练不稳定且难以收敛,因此在 GAN 网络中引入 Wasserstein 距离,使用带梯度惩罚的加权 GAN,即 WGAN-GP,应用两个分布之间的 EM 距离作为目标函数^[8]。EM 距离的原始公式无法求导,因此将其转化为标准的目标函数形式,在分布函数满足 Lipschitz 连续条件(定义域内的梯度不超过某个常数)条件下,EM 距离可表示为:

$$\begin{aligned} & \min_G \max_{D \in \mathcal{Z}} E_{H \sim p_r} [D(H)] - E_{\hat{H} \sim p_r} [D(\hat{H})] \\ & = \min_G \max_{D \in \mathcal{Z}} E_{H \sim p_r} [D(H)] - E_{z \sim p_r} [D(G(z))] \end{aligned} \quad (1)$$

其中 \hat{H} 为生成信道,即为服从高斯分布噪声 z 输入生成器后的输出, $\hat{H} = G(z)$ 。

为了保证 Lipschitz 连续条件,确保训练的稳定性,需要在上式基础上加入梯度惩罚项,产生了如下的目标函数:

$$\min_G \max_D E_{H \sim p_r} [D(H)] - E_{z \sim p_r} [D(G(z))] - \lambda E_{\bar{H} \sim p_s} [(\|\nabla_H D(\bar{H})\|_2 - 1)^2] \quad (2)$$

其中 $\lambda > 0$, $\bar{H} = \epsilon H + (1 - \epsilon)G(z)$, ϵ 为 $0 \sim 1$ 之间均匀分布的采样, $\epsilon \sim u[0, 1]$ 。

该式可看作是 ChannelGAN 的损失函数。训练过程中,生成器 G 的优化目标是损失函数最小化,即判别器对假信道判断为真的概率最大(判断为假的概率最小);判别器 D 的优化目标是损失函数最大化,即真信道判断为真,假信道判断为假的概率最大。

生成器 G 根据输入的噪声向量 z , 输出假信道数据 $\hat{H} = G(z)$, 与真信道数据 H 一同作为判别器的输入。判别器 D 判断输入数据 x 的真假, 输出 $D(x)$ 为判断数据真实的概率, 同时计算 loss, 用于模型的训练。ChannelGAN 网络的基本结构如图 2 所示:

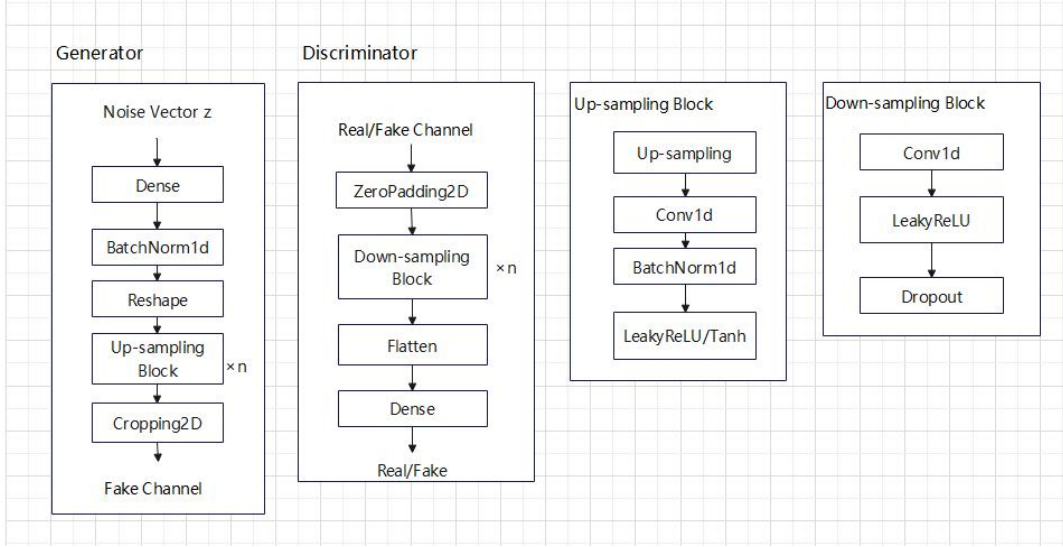


图 2 基于 WGAN-GP 的 ChannelGAN 的网络结构

其中生成器和判别器中分别包含 n 个上采样模块（Up-sampling Block）和 n 个下采样模块（Down-sampling Block）的堆叠。

每个上采样模块包含上采样层、卷积层、批次归一化层，尾部设置一个可选标志 V ，若当前上采样模块不为最后一个，设置 $V=0$ ，若当前模块为生成器的最后一个模块，设置 $V=1$ ，分别表示 LeakyReLU 激活函数（进行非线性变换）和双曲正切函数 \tanh （使数据幅度限制在 $[-1, 1]$ ）。

每个下采样模块包括卷积层、LeakyReLU 激活函数和 dropout 层。

2.2 改进的WGAN-GP

2.2.1 WGAN-GP 基本框架

为了降低数据采集和复杂信道建模的成本，提出一种基于 WGAN-GP 的简单信道建模方案，无需复杂的理论分析和数据处理。利用相似度和多样性指标、归一化信道功率谱和基于深度学习的 CSI 反馈来验证信道建模的交叉性能^[7]。

已知通过引入 Wasserstein 距离和 Lipschitz 函数，可以得到目标函数为式（1），且在此基础上加入梯度约束，得到 ChannelGAN 的损失函数为式（2），改进后的 WGAN-GP 结构有所不同，如图 3 所示：

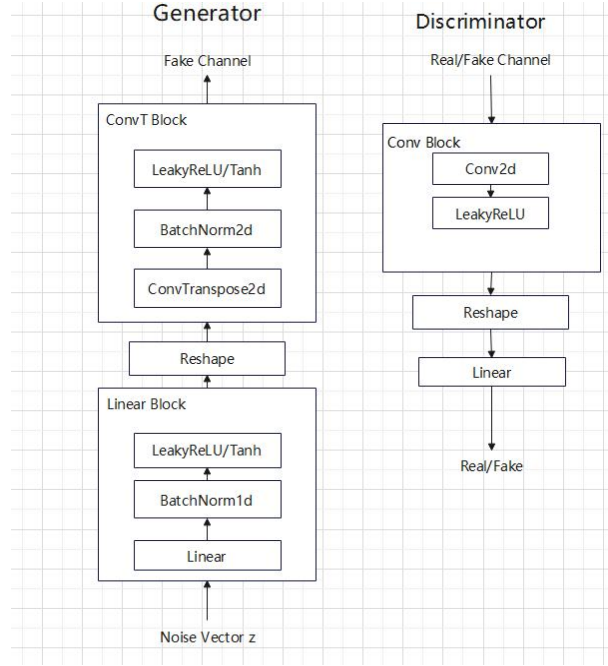


图 3 改进的 WGAN-GP 的网络结构

生成器由一个线性模块（LinearBlock）和 n 个二维反卷积模块（ConvTBlock）组成，线性模块中包含线性层（隐藏维数为 1024）、批次归一化层和激活函数层。线性模块的输出重新调整形状输入反卷积模块，反卷积模块中包含二维反卷积层、二维批次归一化层和激活函数层。两类模块尾部均设置一个可选标志 V ，若当前上采样模块不为最后一个，设置 $V=0$ ，若当前模块为生成器的最后一个模块，设置 $V=1$ ，分别表示 LeakyReLU 激活函数和双曲正切函数 \tanh 。

判别器由 n 个卷积层（ConvBlock）和一个线性层组成。卷积模块包含二维卷积层、LeakyReLU 激活函数层，激活函数的输出重新调整形状为一维向量，输出一个批次内每个数据判断为真的概率。

通过对生成器和判别器的不断训练，生成器可以不断提高其生成类似于真实通道数据的假通道数据的能力，并且判别器可以不断提高其区分真实通道数据和假通道数据的能力。在理想情况下，生成器和判别器通过合作和对抗的机制达成最优解，生成最佳的假信道数据。

2.2.2 WGAN-GP 改进算法

改进 WGAN-GP 的无线信道建模和生成过程分为在线训练和离线生成两个阶段。

在线训练阶段，使用 Adam 优化器训练最优模型参数的生成器 G_{ξ} 和判别器 D_{η} 。离线生成阶段，使用最优参数生成器模型来生成虚假的信道数据。此处生成器的损失函数为 $-\frac{1}{b} \sum_{k=1}^b D_{\eta}(G_{\xi}(z^{(k)}))$ ，判别器的损失函数为 $-\frac{1}{b} \sum_{k=1}^b L^{(k)}$ 。具体的训练

算法将在下文信道矩阵生成部分详细阐述。

2.3 CGAN

2.3.1 CGAN 基本框架

原始的 GAN 生成器只能根据随机噪声 z 进行生成需要的数据，但对这个数据是什么（即标签是什么）我们无从得知，判别器也只能接收输入数据来判断数据是否来自生成器。基于此，我们需要在原始 GAN 的生成器与判别器中的输入中加入额外的约束条件（例如不同类别数据的标签），由此提出了条件生成对抗网络（CGAN）。

条件生成式对抗网络（CGAN）是对原始 GAN 的一个扩展，在 GAN 的基础上针对 GAN 本身不可控的缺点，加入监督信息，指导 GAN 网络进行生成。生成器和判别器都增加额外条件 y ，CGAN 的网络架构如图 4 所示：

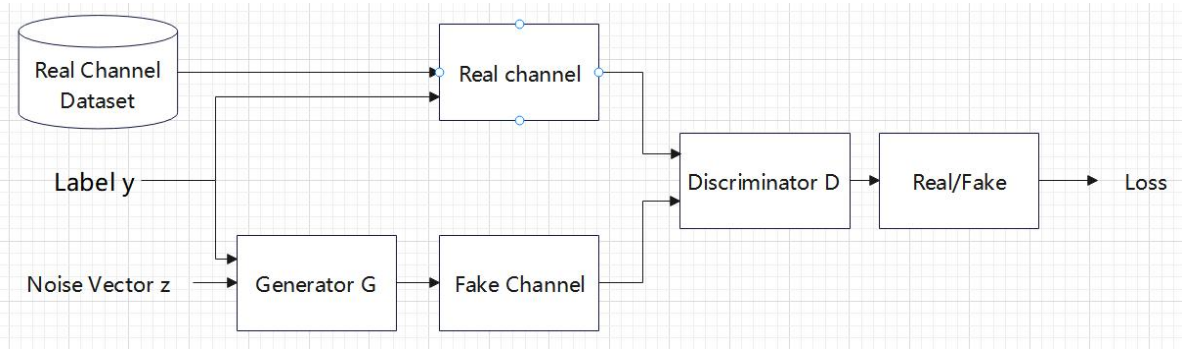


图 4 CGAN 基本网络框架

给定 CGAN 生成器输入噪声 z 和标签 y ，二者拼接后共同输入隐藏层，生成模拟数据。同样地，判别器除真实数据集之外也额外输入标签信息，拼接后共同输入网络，输出判别结果。

因此在 CGAN 中可以通过设置标签对数据集进行分类，实现指定类别的数据生成。CGAN 的目标函数可以表述成如下形式：

$$\begin{aligned} \min_G \max_D V(D, G) = & \mathbb{E}_{x \sim p_{data}(x)} [\log D(x|y)] \\ & + \mathbb{E}_{x \sim p_{data}(z)} [\log(1 - D(G(z|y)))] \end{aligned} \quad (3)$$

2.3.2 CGAN 网络结构

信道数据通常通过频域和天线域上的归一化功率谱表示，在生成与真实信道数据分布相同的假信道数据的基础上，还要求能够生成反映用户处于环境中不同位置的假信道数据。因此考虑引入 CGAN，在原始的生成器和判别器输入中加入标

签，表示所选环境中不同用户位置的信道数据，利用样本数据和对应的标签进行训练，可以定向生成给定标签对应的信道数据。

相对于传统的 GAN 网络模型，CGAN 对生成器和判别器的输入额外加入标签信息，与原本的数据组合后输入模型进行训练，标签信息的应用使网络拥有了更强的分类能力。使用设计好的的基础模块搭建生成网络与对抗网络组成 CGAN 网络架构，如图 5 所示。

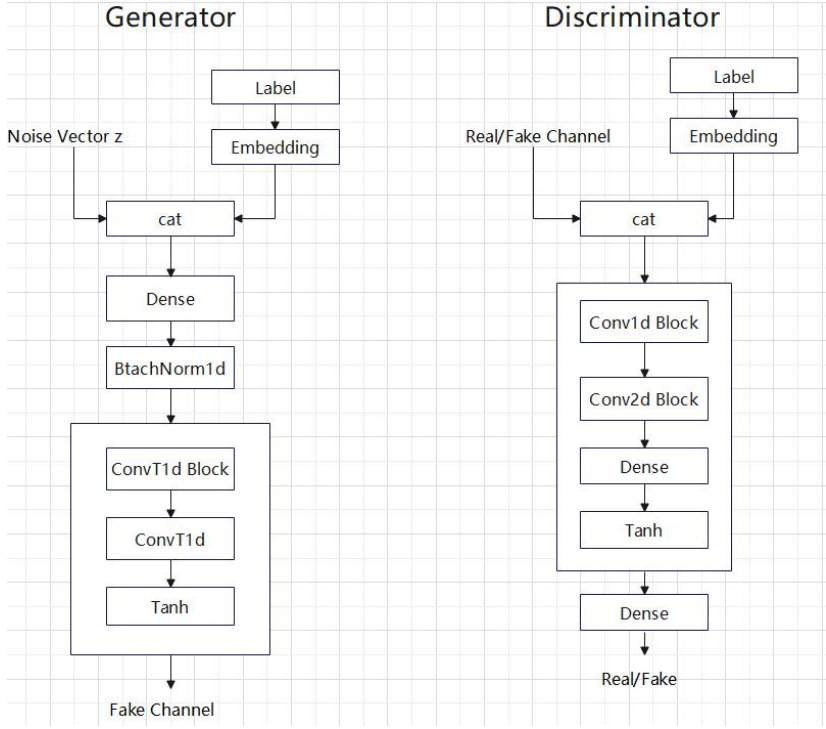


图 5 CGAN 网络基本结构

CGAN 生成器中，标签 Label 先经过 Embedding 函数进行词嵌入，使其第一维度大小与随机噪声 z 相同，Label 与 z 拼接后经过全连接层与批次归一化，输入 n 个堆叠的一维反卷积模块，再经过 Tanh 函数输出与真实信道矩阵形状相同的假信道矩阵。

CGAN 判别器中，Label 同样经过词嵌入后与输入的信道矩阵拼接，输入 n 个一维卷积模块和 m 个二维卷积模块，再经过一个全连接层和 Tanh 函数后输出判断结果，训练得到的生成模型具备在特定条件下生成特定数据的能力。

2.4 ACGAN

2.4.1 ACGAN 基本框架

在条件生成对抗网络（CGAN）的基础上，进一步提出了带辅助分类器的 GAN 即 ACGAN（Auxiliary Classifier Generative Adversarial Network）。结合 CGAN

通过对生成器和判别器均使用标签信息训练的方式来增强原始 GAN 的方法，建立利用辅助标签的 ACGAN^[9]。

ACGAN 与 CGAN 生成器的结构基本相同，生成器输入均为随机的一维噪声和标签信息，不同之处在于 CGAN 输入噪声和标签通常采用拼接的方式组合，ACGAN 的两组输入通常通过对应相乘组合到一起。

ACGAN 与 CGAN 的主要区别在于判别器结构。对于 CGAN，判别器的输入是数据（包含假的或真实的数据）及其标签，输出是数据属于真实的概率^[22]。ACGAN 利用判别器一端来重建标签信息，判别器只输入数据，不输入标签信息，输出端同时输出判别数据为真的概率以及对应的类别标签。ACGAN 在判别器输出端中额外增加交叉熵(softmax)激活函数，通过输出类别反馈学习效果。采用交叉熵损失函数衡量模型对数据的识别性能：

$$\text{Loss} = - \sum_{i=1}^n (y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)) \quad (4)$$

其中 n 为样本数， y_i 、 \hat{y}_i 分别对应第 i 个样本的真实值和预测值。

ACGAN 的损失函数为：

$$L_S = E[\log P(S = \text{real} | X_{\text{real}})] + E[\log P(S = \text{fake} | X_{\text{fake}})] \quad (5)$$

$$L_C = E[\log P(C = c | X_{\text{real}})] + E[\log P(C = c | X_{\text{fake}})] \quad (6)$$

其中 L_S 为判别损失， L_C 为分类损失，表示输入样本对应真实的类别信息的概率。分类损失是 ACGAN 的核心贡献，对于真实图片 X_{real} 和生成器伪造的图片 X_{fake} ，判别器（或者说判别器中的分类器）应该能够预测它所属的类别在训练判别器时，我们希望 $L_S + L_C$ 最大化，在训练生成器时，我们希望 $L_S - L_C$ 最大化。

2.4.2 ACGAN 网络结构

使用 2.1 节中设计的基础模块搭建生成网络与对抗网络组成 ACGAN 网络架构，如图 6 所示，通过参数调整，训练得到的生成模型具备在特定条件下生成特定数据的能力。

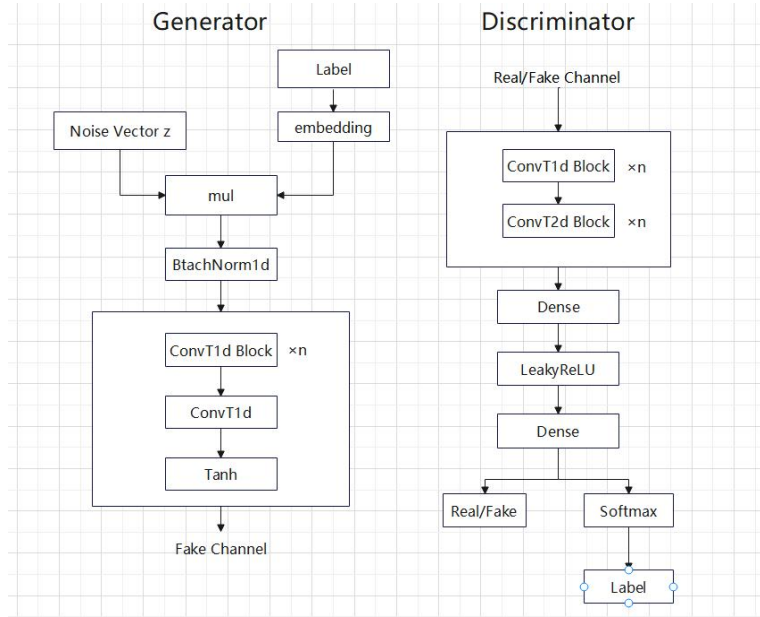


图 6 ACGAN 网络基本结构

ACGAN 和 CGAN 网络结构上的区别主要体现在：生成器输入的经过词嵌入后的标签 Label 和随机噪声 z 通过相乘的方式结合，而非拼接的方式。判别器的输入仅有信道矩阵，没有标签，输出判别结果时额外输出了判断得出的数据标签。

ACGAN 理论认为，强制网络执行其他任务可以提高原始任务的性能，利用辅助标签信息可以产生更高质量的生成样本。

2.5 提出的信道生成网络结构

本文受 ACGAN 网络结构启发，提出了一种具有 WGAN-GP 损失函数和一维卷积块的连续 CGAN 结构，实现了不同用户位置条件下的信道参数生成。网络结构如图 7 所示：

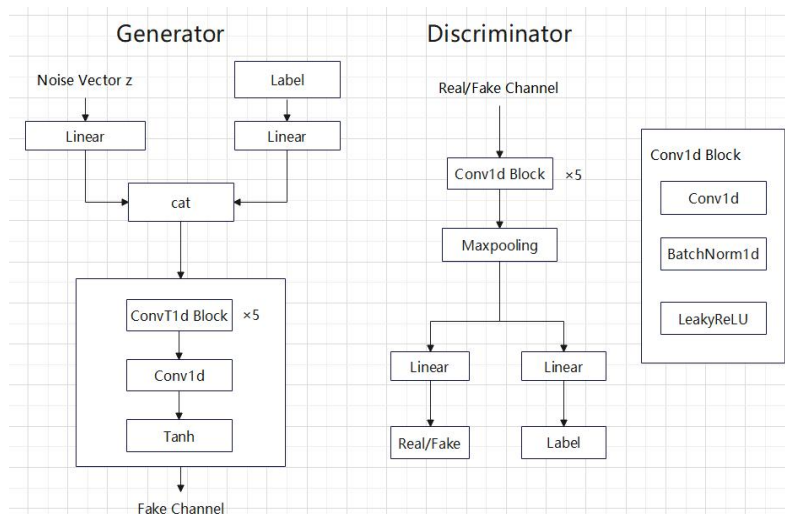


图 7 生成信道路径参数的网络结构

生成器网络结构：服从高斯分布的随机噪声 z 和代表位置坐标的标签 y 经过一层全连接层处理，然后通过拼接的方式输入 G 的一维卷积模块，生成器中有 5 个堆叠的一维卷积模块。每个模块都包含一个 Conv1D 层，一个 BatchNorm1D 层和一个 LeakyReLU 激活函数层，生成器最后一层为 Conv1D 层，输出与 $H \in \mathbb{C}^{N_a \times N_d}$ 具有相同维度的信道参数矩阵。利用一维卷积层，生成器可以学习时延域内的多路径特性。

判别器网络结构：以仿真信道路径参数或生成的信道路径参数作为输入，同样经过 5 个堆叠的一维卷积模块来提取信道参数的特征，然后经过一个 Maxpooling 层将向量拉平，最后经过两个并行的全连接层，分别输出判别结果和对应的条件标签。

2.6 本章小结

本章介绍了生成对抗网络及其部分衍生模型的基本原理，对 WGAN-GP、改进的 WGAN-GP、CGAN、ACGAN 的基本框架进行了阐述，并给出了大致的网络结构。对比了各个模型的优缺点，研究了它们应用于信道数据生成的可行性，为后续模型构建工作提供了理论支撑。

第3章 基于CGAN的信道数据生成

3.1 设计背景

一般通过不同的延迟、功率、出发角、到达角等参数来表征信道模型。为了简单起见，定义真实信道矩阵为 H ，生成的假信道矩阵为 \tilde{H} 。

考虑一个典型的MIMO系统，基站(BS)处发射天线数量为 N_t ，在用户设备(UE)处接收天线数量为 N_r 。因此，在频域中的真实信道可以表示为 $\tilde{H} \in \mathbb{C}^{N_r \times N_t \times N_s}$ ，其中 N_s 表示OFDM子载波的数量。此外，进一步将真实信道重新表示为 $H \in \mathbb{C}^{N_r \times N_t \times N_s}$ ，其归一化元素幅度在 $[-1, 1]$ 中，其中 $N_a = N_t N_r$ 表示天线对的数量。将 \tilde{p}_r 表示为 H 的实际分布，由于理论上需要无限个真实信道数据，因此很难获得。

一般来说，信道建模的过程可以描述为寻找一个假信道，其生成的分布 p_f 旨在匹配真实信道分布 \tilde{p}_r 。它可以表述为

$$\min_{p_f} L(\tilde{p}_r, p_f) \quad (7)$$

其中 $L(\cdot, \cdot)$ 表示测量两个输入分布之间距离的函数，例如Kullback-Leibler散度、Jensen-Shannon散度和EM距离。然而，随着无线信道变得更加复杂，现有的数学信道建模方法很难解释真实的信道分布 \tilde{p}_r ，这给求解(7)带来挑战。

3.2 信道模型

本文通过基于几何的随机几何信道模型描述 L 条路径叠加的信道特征，根据生成的信道路径参数，第 k 个子载波上的信道矩阵可表示为：

$$H_k = \sum_{l=1}^L \alpha_l e^{-j\frac{2\pi k \tau_l}{K}} a_R(\theta_l, \phi_l) a_T^H(\vartheta_l, \varphi_l) \quad (8)$$

其中 α_l ， τ_l ， θ_l/ϕ_l ， ϑ_l/φ_l 分别为第 l 条路径的信道复增益，时延，到达方位/俯仰角，离去方位/俯仰角，接收端天线数 $N_r = N_{r_x} \times N_{r_y} \times N_{r_z}$ ，发射端天线数 $N_t = N_{t_x} \times N_{t_y} \times N_{t_z}$ 。根据UPA的几何形状，导向矢量 $a_R(\theta_l, \phi_l) \in \mathbb{C}^{N_r \times 1}$ 和 $a_T(\vartheta_l, \varphi_l) \in \mathbb{C}^{N_t \times 1}$ 分别表示为

$$\begin{aligned} a_R(\theta_l, \phi_l) &= a_{R_x}(\theta_l, \phi_l) \otimes a_{R_y}(\theta_l, \phi_l) \otimes a_{R_z}(\phi_l), \\ a_T(\vartheta_l, \varphi_l) &= a_{T_x}(\vartheta_l, \varphi_l) \otimes a_{T_y}(\vartheta_l, \varphi_l) \otimes a_{T_z}(\varphi_l) \end{aligned} \quad (9)$$

同时定义

$$\begin{cases} a_{R_x}(\theta_l, \phi_l) = e^{j2\pi\frac{d}{\lambda}\cos\theta_l\sin\phi_l\mathbf{n}_1} \\ a_{R_y}(\theta_l, \phi_l) = e^{j2\pi\frac{d}{\lambda}\sin\theta_l\sin\phi_l\mathbf{n}_2} \\ a_{R_z}(\theta_l, \phi_l) = e^{j2\pi\frac{d}{\lambda}\cos\phi_l\mathbf{n}_3} \\ a_{T_x}(\vartheta_l, \varphi_l) = e^{j2\pi\frac{d}{\lambda}\cos\vartheta_l\sin\varphi_l\mathbf{m}_1} \\ a_{T_y}(\vartheta_l, \varphi_l) = e^{j2\pi\frac{d}{\lambda}\sin\vartheta_l\sin\varphi_l\mathbf{m}_2} \\ a_{T_z}(\vartheta_l, \varphi_l) = e^{j2\pi\frac{d}{\lambda}\cos\varphi_l\mathbf{m}_3} \end{cases} \quad (10)$$

其中

$$\mathbf{n}_1 = [0, 1, \dots, N_{r_x} - 1]^T, \mathbf{n}_2 = [0, 1, \dots, N_{r_y} - 1]^T, \mathbf{n}_3 = [0, 1, \dots, N_{r_z} - 1]^T, \mathbf{m}_1 = [0, 1, \dots, N_{t_x} - 1]^T, \mathbf{m}_2 = [0, 1, \dots, N_{t_y} - 1]^T, \mathbf{m}_3 = [0, 1, \dots, N_{t_z} - 1]^T$$

频域信道矩阵大小为 $N_r \times N_t \times N_s$ ，其中 OFDM 子载波数 $N_s = 64$ ，接收天线数 $N_r = 4$ ，发射天线数 $N_t = 32$ ，将发射天线和接收天线组成的天线对作为一个维度，即 $N_r \times N_t = N_a = 4 \times 32 = 128$ ，此时信道矩阵 $\mathbf{H} \in \mathbb{C}^{N_a \times N_s}$ 。

3.3 数据集建立

训练与测试数据集通过 DeepMIMO 生成。DeepMIMO 是一种基于精确 Remcom 3D Ray-tracing 的大规模 MIMO 数据集生成框架，DeepMIMO 中的数据集完全由射线追踪场景和参数集定义，支持广泛的机器/深度学习的通信和传感应用^[23]。DeepMIMO 数据集是根据 Remcom Wireless InSite 中的精确射线追踪数据构建的，因此 DeepMIMO 生成的信道数据能够一定程度上反映信道的环境特性（如物体几何形状、物体材料、发射机/接收机位置），这一特点有利于神经网络对信道特征的感知。

同时，DeepMIMO 数据集具有参数化的特点，可以通过调整部分生成参数，为目标数据的机器学习自定义数据集适用于不同模型的训练，具有很强的通用性。DeepMIMO 数据集可以通过 Remcom Wireless InSite 对应采用的光线追踪场景或参数集来准确表示，从而能够准确定义和再现数据集。

本文中，DeepMIMO 数据集的通信场景选取 01 方案，01 射线追踪场景是两条街道和十字路口的户外场景，俯视图如图所示，该场景为具有两条街道和一个十字路口的户外场景，主要街道（水平街道）长 600 米，宽 40 米，十字街（垂直街）长 440 米，宽 40 米，两条街道两边都有建筑物。拥有 18 个基站（BS）和三个用

户网格（UG），共有超过 100 万候选用户，所有基站高度均为 6m。用户的高度相同，相邻用户之间的间距均为 20cm。本文中选取第一个用户网格中的前 1000 行，每行 181 个用户，即 181000 个用户作为总数据集，所选区域为 200 米长，36 米宽，用户坐标范围为（242-278，297-497）。设置批次大小为 181，共得到 1000 批次用户数据，从中等间隔选取 100 批次用户数据作为训练数据集，随机选取 150 批次作为测试数据集。基站天线和用户天线均为均匀平面天线阵列（UPA），基站天线数为 $1 \times 8 \times 4$ ，用户天线数为 $1 \times 2 \times 2$ 。



图 8 01 射线追踪场景俯视图




图 9 01 射线追踪场景鸟瞰图

通过 python 代码加载 DeepMIMO 数据集，并进行参数设置，具体设置如表 1 所示。

表 1 数据集参数设置

| 参数 | 数值 |
|----------|-----------------------|
| 工作频率 | 60GHz |
| 带宽 | 100MHz |
| 子载波数 | 64 |
| 最大延迟路径数 | 10 |
| Tx 天线数 | $1 \times 8 \times 4$ |
| Rx 天线数 | $1 \times 2 \times 2$ |
| 批次大小 | 181 |
| 学习率 | $2e-4$ |
| 训练轮次 | 150 |
| 训练数据集批次数 | 100 |
| 测试数据集批次数 | 150 |

信道的射线追踪路径参数在 DeepMIMO 数据集中以字典的形式提供,具体来说,对于每条路径,信道特征包含:方位到达角和俯仰到达角(AAoA, EAoA),方位出发角和俯仰出发角(AAoD, EAoD),路径时延(τ),相位,功率。信道数据可表示为 $H \in \mathbb{C}^{N_a \times N_d}$,其中 N_a 为每条路径信道特征的数量, N_d 为设置的最大路径数量。根据参数设置,最大路径数为 10,对路径数不足 10 的数据进行补零,并对数据集进行归一化和标准化,得到的信道矩阵尺寸即为 $1 \times 7 \times 10$ 。

3.4 网络训练

生成器 G 和判别器 D 的训练交替迭代进行,生成器和判别器基于损失函数,利用和最优化方法(如梯度下降法)来实现参数的调整,不断提高生成网络和判别网络的性能即 G 和 D 分别使联合损失最小化和最大化,最终实现生成器 G 可以稳定生成符合真实信道特征的数据,此时判别器 D 判断的概率应为 $1/2$ ^[24]。

使用Adam优化器训练最优模型参数的生成器 G_ξ 和判别器 D_η ,设置生成器和判别器的网络参数分别为 ξ 和 η 。设置Adam超参数时应注意选择合适的学习率,若学习率设置过大,则在每一步的迭代中,参数模型可能会跨过最优解,导致loss震

荡或发散，若学习率设置过小，模型收敛到最优解的速度将会非常慢，且有可能陷入局部极小点，而非全局最优解^[25]。此处采用了随训练过程的进行调整学习率的方法，初始设置学习率 $lr = 2e^{-4}$ ，训练一定轮次后将学习率除以10，有助于使模型在训练中更好地收敛。 $\beta_1 = \beta_2 = 0.9$ ，梯度惩罚系数 $\lambda = 10$ 。生成器每迭代一次，判别器迭代次数为 n_{critic} 。训练轮次数和批次大小分别为 e 和 b 。真信道 \mathbf{H} 随机采样得到训练数据 \mathbf{H}' ，随机噪声 z 经过生成器得到 $G_\xi(z)$ ，判别器 D 的损失函数引入梯度惩罚，可以表示为：

$$L_D = E_{\mathbf{H} \sim p_r} [D(\mathbf{H})] - E_{z \sim p_z} [D(G(z))] - \lambda E_{\bar{\mathbf{H}} \sim p_s} [(\|\nabla_{\bar{\mathbf{H}}} D(\bar{\mathbf{H}})\|_2 - 1)^2] \quad (11)$$

其中 \mathbf{H} 为真实信道数据对应的矩阵， p_r 代表其真实分布， z 为随机噪声， p_z 表示高斯分布， \mathbf{y} 和 $\tilde{\mathbf{y}}$ 分别为仿真信道数据和生成信道数据对应的位置坐标。 λ 梯度惩罚项系数，设为10， $\bar{\mathbf{H}} = \epsilon \mathbf{H} + (1 - \epsilon)G(\mathbf{z})$ ， ϵ 为0-1之间均匀分布的采样， $\epsilon \sim u[0, 1]$ 。

生成器 G 的损失函数可以表示为：

$$L_G = -E_{z \sim p_z} [D(G(z|\mathbf{y}))] + \lambda_w \|\tilde{\mathbf{y}} - \mathbf{y}\|_2^2 \quad (12)$$

其中 L_G 的前一项为生成损失，被训练为最小化的Wasserstein距离，第二项为回归损失，利用二阶范数来测量仿真数据与生成数据位置标签之间的差值，损失权重系数 $\lambda_w = 1$ 。

利用 Adam 优化器，根据网络参数（ ξ 或 η ）、损失函数、Adam 超参数对模型权重进行更新，轮次和批次大小分别为 e 和 b 。GAN 网络训练困难，判别器训练太差时无法为生成器提供有效梯度，训练太好则会导致梯度消失，影响生成器的训练。为了解决这一问题，训练时首先固定生成器，判别器每训练一定次数生成器训练一次，可以降低学习难度，提升系统的收敛速度。

首先更新判别器权重 η ，更新 n_{critic} 次后，更新一次生成器权重 ξ 。经过训练后，输出模型 $G_\xi(\cdot)$ 和 $D_\eta(\cdot)$ 。

算法 1: 改进的 WGAN-GP 算法

初始化: 设置生成器和判别器的网络参数分别为 ξ 和 η , Adam 超参数: $lr = 2e^{-4}$, $\beta_1 = \beta_2 = 0.9$, 梯度惩罚系数 $\lambda = 10$, 损失权重系数 $\lambda_w = 1$ 。

输入: 生成器每迭代一次, 判别器迭代次数 $n_{critic} = 3$ 。训练轮次数和批次大小分别为 e 和 b 。

for $i \leftarrow 1$ to e do

for $j \leftarrow 1$ to n_{critic} do

for $k \leftarrow 1$ to b do

从真实信道数据 H 中抽样得到训练数据集 H' , 对应位置的标签为 y 噪声向量 $z \sim p_z$, 随机采样系数 $\alpha \sim U[0,1]$

$$\hat{H}' \leftarrow G_{\xi}(z)$$

$$\bar{H} \leftarrow \alpha H' + (1 - \alpha) \hat{H}'$$

$$gp \leftarrow \lambda (\|\nabla_{\bar{H}} D_{\eta}(\bar{H}|y)\|_2 - 1)^2$$

$$L_D^{(k)} \leftarrow D_{\eta}(\hat{H}') - D_{\eta}(H') + gp$$

end

$$\eta \leftarrow Adam(\nabla_{\eta} \frac{1}{b} \sum_{k=1}^b L_D^{(k)}, \eta, lr, \beta_1, \beta_2)$$

end

随机生成一个批次的噪声向量 $\{z^{(k)}\}_{k=1}^b \sim p_z$

$$L_G^{(k)} \leftarrow -D_{\eta}(G_{\xi}(z^{(k)})) + \lambda_w \|\tilde{y} - y\|_2^2$$

$$\xi \leftarrow Adam(\nabla_{\xi} \frac{1}{b} \sum_{k=1}^b L_G^{(k)}, \xi, lr, \beta_1, \beta_2)$$

end

输出: $D_{\eta}(\cdot), G_{\xi}(\cdot)$

判别器 D 的训练: 每个训练轮次中, 将真实信道数据集 H 中获得的训练数据样本输入生成器 G , 同时将随机噪声向量 z 与训练数据集中的表示用户位置的标签一同按批次输入生成器 G , 输出生成信道矩阵 \hat{H}' , 再根据实信道数据集 H 中获得的训练数据集样本 H' 和与其标签一一对应的生成信道数据 \hat{H}' , 结合梯度惩罚

系数 λ ，计算损失函数中是梯度惩罚项 gp 。将 \hat{H}' 和 H' 与其对应标签分别输入判别器D，分别输出同一标签下真实数据和生成数据判断为真实数据的概率，结合梯度惩罚项 gp 计算 WGAN-GP 损失函数，将其输入判别器的 Adam 优化器，输出这个训练轮次更新后的判别器权重。

生成器G的训练：生成器模型更新 n_{critic} 次后，将一个批次的服从高斯分布的噪声 z 和该批次对应的标签共同输入生成器，输出模拟信道矩阵 $G_{\xi}(z)$ ，再将 $G_{\xi}(z)$ 和输入判别器，输出判断该批次生成信道矩阵为真的概率 $D_{\eta}(G_{\xi}(z))$ ，结合回归损失，计算生成器G的损失函数，将其输入生成器的 Adam 优化器，输出这个训练轮次更新后的生成器权重。

在上述训练过程中，真信道分布 p_r 和假信道分布 p_f 的 EM 距离即 $L(p_r, p_f)$ 逐渐减小， p_r 和 p_f 分别越来越相似，当该网络收敛时，生成器G可以较好的模仿真实信道，生成大量模拟信道数据，以支持无线信道建模相关任务。

3.5 信道生成仿真结果

3.5.1 信道数据生成

经过神经网络训练后，信道矩阵损失函数收敛情况如图10所示。




图10 生成器与判别器损失函数收敛情况

蓝色曲线为判别器损失 D_loss ，橙色曲线为生成器损失 G_loss 。训练至150轮时，生成器和判别器均已达到收敛状态。保存训练完成后生成器和判别器的权重，

将测试数据集（包括信道矩阵与其对应的位置标签）输入生成器模型，即可输出生成的信道路径参数。

手动输入用户位置坐标，可以生成一定范围内任意位置用户与选定基站之间的信道路径参数，包括原先的训练数据集中没有的位置标签对应的路径参数。为了更直观地体现模型生成数据与真实数据的相似性，根据式（8）进一步得到对应用户位置的频域信道矩阵，由此可实现模拟信道数据的大量生成。基于路径参数的信道数据在不同位置条件下生成的数据和仿真信道数据映射为频域信道矩阵的对比如图11所示。




图11 根据用户坐标生成基于路径信息信道矩阵：

(a) $x=250, y=300$, (b) $x=250, y=600$, (c) $x=270, y=300$, (d) $x=270, y=600$

3.5.2 真假信道功率时延谱对比

为了进一步验证所提出的信道建模方法的有效性，在选定的用户范围内模拟了一个接收站在用户网格中移动的场景，目标沿选定的位置构成的轨迹移动，如图 12 所示。


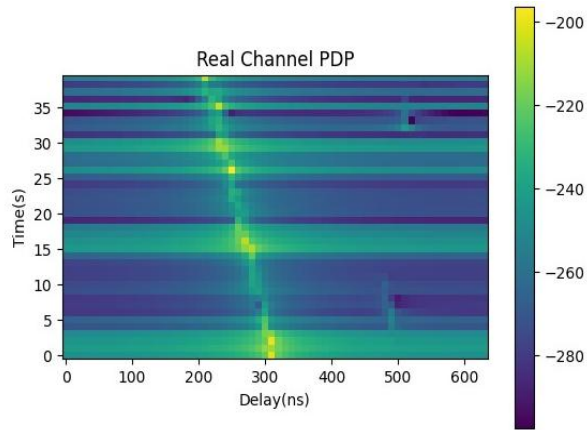
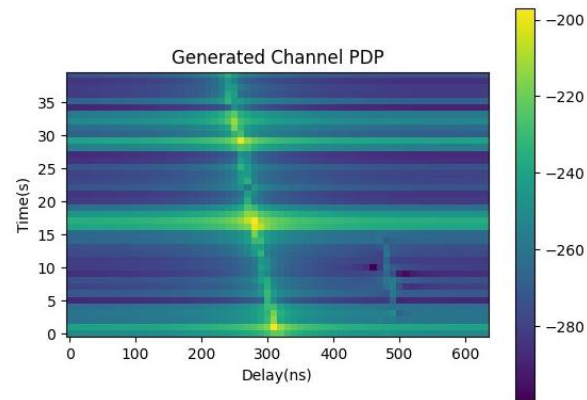


图 12 模拟接收站在用户网格范围内的运动轨迹

假定目标每秒经过一个原网格中用户对应位置，每经过一个位置，根据相应的频域信道矩阵，计算该运动轨迹对应的随时间变化的功率时延谱 $PDP = |h(t, \tau)|^2$ 。通过仿真信道数据和生成信道数据分别得出该场景下 PDP 如图 13 所示。



(a)



(b)

图 13 信道频域矩阵对应的功率时延谱：(a) 仿真信道矩阵对应的功率时延谱, (b) 生成信道矩阵对应的功率时延谱

生成信道模型的时延特征、路径细节与仿真信道数据有较高的一致性。

真假信道数据对比的结果表明，基于 ACGAN 和 WGAN-GP 的神经网络模型能够较好地模拟真实信道，生成的路径参数有一定的有效性，能够一定程度上替代真实信道数据形成广泛的训练数据集以支持相关的基于 DL 的无线通信任务^[26]，大大减少了对真实信道数据量的需求。生成的天线间阵列矩阵的有效性还有待提高，仍需优化网络结构。

3.6 本章小结

本章构建了基于WGAN-GP和ACGAN的网络模型，加载DeepMIMO数据集并进行了数据预处理，构建了信道路径参数的数据集。根据数据集的特征构建ACGAN和WGAN-GP结合的网络模型，并根据改进的WGAN-GP算法计算损失函数，确定训练方法，完成生成器和判别器的更新。

第4章 总结与展望

本文对生成对抗网络及其衍生模型的基础理论做了详细阐述，明确了在无线信道建模中引入 GAN 的理论可行性。针对传统 GAN 中的数据分类问题，在 GAN 中引入标签，研究了基于 CGAN 的信道建模方法；针对 GAN 网络训练不稳定和生成器损失函数参数不合理等问题，引入平滑的 Wasserstein 距离，针对生成器梯度消失严重的问题，在损失函数中加入梯度惩罚，确定了基于 WGAN-GP 损失函数的模型训练算法。

在此基础上，提出了结合 ACCGAN 网络结构和 WGAN-GP 训练算法的无线信道建模方法，通过 DeepMIMO 生成了一种室外多用户场景下的信道数据集，训练了构建的网络模型，实现了位置坐标连续的信道路径参数生成，经过测试集验证，能够根据输入的不同位置信息生成对应位置用户与选定基站之间的模拟信道数据。对真实信道数据和生成的信道数据进行了对比，验证了基于 GAN 进行无线信道建模的可行性。

由于时间有限，部分关键性问题还有待改进优化：

（1）将模型扩展到更大范围更复杂的场景。本文所提出的 GAN 网络信道建模主要应用于较为简单室外十字路口模型，但实际情况大多涉及到更加复杂的通信环境，未来可以考虑考虑更接近实际场景的 MIMO 系统。

（2）对神经网络作进一步优化。目前提出的神经网络在处理信道数据时，只考虑用户位置这一标签与信道数据关联性，还可以考虑添加其他分类标签，如在改变接收站位置的基础上进一步改变发射站位置，引入二维标签。

（3）考虑其他 GAN 衍生模型。除本文中讨论的各种模型之外，相关研究已经提出的模型还包括 DCGAN、infoGAN、SGAN 等多种模型。分析每种模型的优缺点，尝试寻找不同信道类型适用的模型，可以提高基于 GAN 信道建模方法的泛用性与有效性。

参考文献

- [1] Tan J, Dai L. Wideband Channel Estimation for THz Massive MIMO[J]. China Communications, 2021, 18(5): 66-80.
- [2] 孟婵媛, 熊轲, 高博, 等, 面向 6G 的生成对抗网络研究进展综述[J/OL]. (2023-09-26). <https://link.cnki.net/urlid/10.1491.TP.20230925.1553>.
- [3] Wenwu Xie, Ming Xiong, Zhihe Yang, Wei Liu, Lvrong Fan, Jian Zou. Real and fake channel: GAN-based wireless channel modeling and generating[J]. Physical Communication, 2023, 61, 102214
- [4] GOODFELLOW I. Generative adversarial nets[C]. Montreal, Canada: IEEE, 2014: 2672-2680
- [5] MIRZA M, OSINDERO S. Conditional generative adversarial nets[J]. Computer Science, 2014, 9(8): 2672-2680
- [6] DENTON E L, CHINTALA S, FERGUS R. Deep generative image models using a laplacian pyramid of adversarial networks[C]. Vancouver, Canada: IEEE, 2015: 1486-1494
- [7] ARJOVSKY M, CHINTALA S, BOTTOU L. Wasserstein generative adversarial networks[C]. Sydney, Australia: IEEE, 2017: 214-223
- [8] GULRAJANI I, AHMED F, ARJOVSKY M, et al. Improved training of wasserstein GANs[C]. California, USA: IEEE, 2018: 5769-5779.
- [9] 陈昌美, 李艳斌, 杨鸿杰, 等. 基于条件生成对抗网络的信号生成技术[J]. 信息技术, 2023, 1(10): 136-146
- [10] Yang Yang, Yang Li, Wuxiong Zhang. Generative-Adversarial-Network-Based Wireless Channel Modeling: Challenges and Opportunities[J]. IEEE Communications Magazine, 2019, 57(3): 22-27
- [11] Li Y, GAN Z, SHEN Y, et al. StoryGAN: a sequential conditional GAN for story visualization[C]. Long Beach, CA, USA: IEEE, 2019
- [12] HJELM RD, JACOB AP, CHE T, et al. Boundary-seeking generative adversarial networks[J]. IEEE Access, 2018, 6(1): 2169-3536
- [13] W. Xia et al. Generative neural network channel modeling for millimeter-wave UAV communication[J]. IEEE Trans. Wireless Commun. 2022, 21(11): 9417-9431.
- [14] Y. Tian et al. Generative Network-Based Channel Modeling and Generation for Air-to-Ground Communication Scenarios. IEEE Communications Letters, 2024, 28(4): 892-896
- [15] O' SHEA T J, KARRA K, Clancy T C. Learning to communicate: Channel auto-encoders, domain specific regularizers, and attention[C]. 2016 IEEE International Symposium on Signal Processing and Information Technology (ISSPIT). Limassol, Cyprus: IEEE, 2016: 1-6.
- [16] O' SHEA T J, ROY T, WEST N, et al. Physical Layer Communications system design over-the-air using adversarial networks[C]. 2018 26th European Signal Processing Conference (EUSIPCO). Rome, Italy: IEEE, 2018: 529-532.
- [17] 王旭东, 吴楠, 王旭. 基于卷积神经网络自编码器结构的空时分组传输方案[J]. 电讯技术, 2020, 60(07): 746-752.

- [18]H. Huang et al. Deep Learning for Physical-Layer 5G Wireless Techniques: Opportunities, Challenges and Solutions. *IEEE Wireless Communications*, 2020, 27(1): 214-222.
- [19]H. Xiao et al. AI enlightens wireless communication: Analyses, solutions and opportunities on CSI feedback. *China Communications*, 2021, 18(11):104-116.
- [20]H. Xiao, W. Tian, W. Liu and J. Shen. ChannelGAN: Deep Learning Based Channel Modeling and Generating[J]. *IEEE Wireless Commun. Lett.*, 2022, 11(3):650-654
- [21]D. Singh and A. K. Reddy Chavva. Modeling time-varying and Frequency-Selective Channels with Generative Adversarial Networks[C]. *Proc. IEEE Int. Conf. Commun. (ICC)*, Seoul, Korea, 2022:5329-5334.
- [22]J. Su, X. Gao, Y. Qin and S. Guo. Correcting Corrupted Labels Using Mode Dropping of ACGAN[C]. 2021 15th International Symposium on Medical Information and Communication Technology (ISMICT), Xiamen, China, 2021:98-103.
- [23]E. G. Larsson, O. Edfors, F. Tufvesson, and T. L. Marzetta. Massive MIMO for Next Generation Wireless Systems[J]. *IEEE Communications Magazine*, 2014, 52(2):189-195
- [24]M. Zhou, J. Wang and H. Sun. Wasserstein GAN Based Underwater Acoustic Channel Simulator[C]. *ZHENGZHOU, China:2023 IEEE International Conference on Signal Processing, Communications and Computing (ICSPCC)*, 2023
- [25]R. J. Williams. Simple Statistical Gradient-Following Algorithms for Connectionist Reinforcement Learning[J]. *Machine learning*, 1992, 8(3-4):229 - 256.
- [26]Hu Y, Yin M, Xia W, et al. Multi-Frequency Channel Modeling for Millimeter Wave and THz Wireless Communication via Generative Adversarial Networks[C]. *Pacific Grove, CA, USA*, 2022: 670-676.

致 谢

在完成这篇论文之际，我谨向所有在研究过程中给予我帮助和支持的人和组织表达最诚挚的谢意。

首先，我要感谢我的导师孙健老师。在整个研究过程中，您始终给予我悉心的指导和耐心的解答。您深厚的学术造诣、严谨的治学态度和不断创新的精神，不仅使我在学术上受益匪浅，更让我在人生道路上受益匪浅。您的教诲和激励一直是我前进的动力，您的悉心指导和热情帮助使我在研究过程中少走了许多弯路。

同时，我要感谢我的同学们。在研究过程中，我们互相学习、互相启发，共同攻克了许多难题。你们的支持和鼓励让我在遇到困难时能够坚持不懈，你们的意见和建议使我的研究更加完善。我们之间的友谊和合作精神将成为我人生中宝贵的财富。

此外，我还要感谢我的家人和朋友们。你们一直是我坚实的后盾，给予我无条件的支持和关爱。在我遇到挫折和困难时，你们总是鼓励我、安慰我，让我能够重新振作起来。没有你们的支持和理解，我无法顺利完成这篇论文。

回顾整个研究过程，我遇到了许多挑战和困难。然而，正是这些挑战和困难使我不断成长和进步。在这个过程中，我不仅学到了专业知识，更学会了如何面对问题和解决问题。我相信，这段经历将成为我未来工作和生活的宝贵财富。